

PROJEKTNI ZADATAK

projektovanje CNN i fuzzy regulatora

Sofija Nikolić: SI, 2023/0603

Mina Ostojić: SI, 2023/0368

Projektovanje potpuno konvolucione neuralne mreže

Opis problema i primjerci po klasama


Skup podataka koji je korišćen u ovom projektu je UTKFace dataset, koji sadrži slike ljudskih lica anotiranih po starosti, polu i etničkoj pripadnosti. Za potrebe ovog projekta, klasifikacija je vršena prema etničkoj pripadnosti, pri čemu su definisane sledeće klase: *white*, *black*, *asian*, *indian* i *other*. Ulazni podaci su RGB slike lica, veličine 96×96 piksela nakon preprocesiranja. Ukupan broj uzoraka u datasetu iznosi 23.705.

U cilju vizuelizacije ulaznih podataka, prikazan je po jedan reprezentativni primjerak iz svake od pet klasa. Na slici se može uočiti da su slike lica različitih osoba, snimljene u različitim uslovima osvetljenja i sa različitim pozama.

Rasodela slika po klasama je sledeća:


<i>Klasa</i>	<i>Broj slika</i>	<i>Udio</i>
asian	3434	14%
black	4526	19%
indian	3975	17%
other	1692	7%
white	10078	42%
ukupno	23705	100%

Po jedan primjerak iz svake klase



Histogram raspodele klasa i balansiranost

Na histogramu raspodele uzoraka po klasama može se uočiti da dataset **nije balansiran**. Klasa *white* sadrži 10078 uzoraka (~42%), dok klasa *other* sadrži svega 1692 uzoraka (~7%), što predstavlja odnos gotovo 6:1. Ostale klase (*black* ~19%, *indian* ~17%, *asian* ~14%) su zastupljene u umerenom obimu.



Ovakva neravnomjerna raspodela može dovesti do toga da model tokom treniranja postane pristrasan prema zastupljenijim klasama, tj. da češće predviđa klase sa više primjeraka, nauštrb manjinskih klasa.

Da bismo izvršili balansiranje klasa, neophodno je da najpre podelimo podatke na trening, test i validacioni skup.

Podela na trening, validacioni i test skup

Skup podataka je podijeljen na tri disjunktna podskupa: trening skup (70%), validacioni skup (15%) i test skup (15%). Trening skup se koristi za optimizaciju parametara modela, validacioni skup za praćenje performansi tokom treniranja i sprečavanje preobučavanja, dok se test skup koristi isključivo za finalnu evaluaciju modela nakon završenog treniranja.

Podaci se učitavaju u batch-evima veličine 64 slike. Od ukupno 371 batch-a, 259 pripada trening skupu, 55 validacionom skupu i 57 test skupu, što odgovara raspodeli od približno 70%-15%-15%.

Balansiranje klasa

Kao tehnika za rješavanje ovog problema primijenjena je metoda **ponderisanja klasa** (engl. *class weighting*) na trening skup. Ovom metodom se svakoj klasi dodjeljuje težinski koeficijent obrnuto proporcionalan njenoj zastupljenosti u datasetu — manjinskim klasama se dodjeljuje veća težina, čime se modelu signalizira da greške na tim klasama treba više da "kažnjava". Na taj način model tokom treniranja posvećuje podjednaku pažnju svim klasama, bez obzira na njihovu brojnost.

U odnosu na tehnike poput oversamplinga i undersamplinga, primenjen je ovaj pristup, s obzirom na to da je broj uzoraka po klasi dovoljno velik, čime se izbegava potreba za generisanjem dodatnih ili uklanjanjem postojećih podataka.

Generisane težine klasa:

Klasa	Težina
asian	1.362037797863599
black	1.0467950742027154
indian	1.1942363112391932
other	2.7649708090075062
white	0.4736

Kao što se može uočiti, klasa *other* ima najveću težinu (2.76) jer je najslabije zastupljena, dok klasa *white* ima najmanju težinu (0.47) kao dominantna klasa.

Preprocesiranje - normalizacija i augmentacija

U procesu preprocesiranja primijenjene su sljedeće transformacije:

1. Normalizacija: Vrijednosti piksela su skalirane sa opsega [0, 255] na opseg [0, 1] dijeljenjem sa 255. Pikseli originalnih slika imaju cjelobrojne vrijednosti u opsegu [0, 255]. Neuronske mreže efikasnije uče kada su ulazne vrijednosti male i u ujednačenom opsegu, pa normalizacija ubrzava konvergenciju i poboljšava numeričku stabilnost tokom treniranja.

2. Augmentacija podataka: Primijenjena je isključivo na trening skup, u cilju umjetnog povećanja raznolikosti podataka i smanjenja rizika od preobučavanja. Korišćene su sljedeće transformacije:

- *RandomFlip (horizontal)* — nasumično horizontalno zrcaljenje slike, što simulira lica okrenuta na različite strane
- *RandomRotation (10%)* — nasumična rotacija slike do 10%, što simulira različite nagibe glave
- *RandomZoom (10%)* — nasumično zumiranje do 10%, što simulira različite udaljenosti lica od kamere
- *RandomTranslation (10%)* — nasumično pomjeranje slike do 10%, što simulira različite pozicije lica u kadru

Sve navedene transformacije su realistične i odgovaraju varijacijama koje se prirodno javljaju u skupovima slika lica. Augmentacija je primijenjena samo na trening skup — validacioni i test skup ostaju nepromijenjeni, jer oni služe za objektivnu evaluaciju modela na realnim, nemodifikovanim podacima. Na ovaj način preprocesiranje doprinosi kako stabilnosti treniranja tako i sposobnosti generalizacije modela na nove podatke.

Postupak prenosa znanja

Kriterijumska funkcija: Korišćena je `SparseCategoricalCrossentropy` koja je pogodna za višeklasnu klasifikaciju kada su labelle predstavljene kao cijeli brojevi (0, 1, 2, 3, 4), a ne kao one-hot vektori.

Funkcije aktivacije: U skrivenim slojevima korišćena je `ReLU` (Rectified Linear Unit) aktivacija koja rješava problem nestajanja gradijenata i ubrzava treniranje. U izlaznom sloju korišćena je `softmax` aktivacija koja transformiše izlaze mreže u vjerovatnoće po klasama čiji je zbir uvijek 1.

Metoda optimizacije: Korišćen je `Adam` optimizator sa podrazumijevanom stopom učenja (`1e-3`), koji adaptivno prilagođava stopu učenja za svaki parametar.

Opis MobileNetV2: MobileNetV2 je konvoluciona neuronska mreža dizajnirana za efikasnu klasifikaciju slika na uređajima sa ograničenim resursima. Zasnovan je na depthwise separable konvolucijama koje drastično smanjuju broj parametara u poređenju sa klasičnim CNN arhitekturama. Prednosti modela su mala veličina (2.2M parametara), brzo treniranje i visoke performanse. Mana je što može biti manje precizan od većih modela poput ResNet50 ili VGG16 na kompleksnim zadacima.

Postupak prenosa znanja: Primijenjen je jednofazni pristup. U prvoj fazi, težine MobileNetV2 baze su zamrznute i treniran je samo klasifikacioni dio (173k parametara). Prvobitno je primenjen dvofazni pristup, međutim, nakon uvida u rezultate koji su pokazali da tačnost modela opada nakon izvršenja druge faze (fine-tuning), donesena je odluka da se model trenira u jednoj fazi.

Zaštita od preobučavanja

Preobučavanje (engl. *overfitting*) je pojava kada model previše dobro nauči trening skup, uključujući i šum u podacima, te gubi sposobnost generalizacije na nove, neviđene podatke. Manifestuje se kao velika razlika između tačnosti na trening i validacionom skupu, gde pritom tačnost na validacionom skupu opada, odnosno gubitak raste.

Kao zaštita od preobučavanja primijenjene su sljedeće tehnike:


Dropout — tokom treniranja se nasumično isključuje određeni procenat neurona (50% nakon prvog Dense sloja i 30% nakon drugog). Na taj način mreža ne može da se osloni na određene neurone i prisiljena je da uči robusnije reprezentacije.

EarlyStopping — treniranje se automatski zaustavlja ukoliko se **val_accuracy** ne poboljšava tokom 5 uzastopnih epoha, pri čemu se vraćaju težine iz najbolje epohe.

BatchNormalization — normalizuje aktivacije između slojeva tokom treniranja, što stabilizuje i regularizuje proces učenja.

Rezultati i prikaz performansi

Grafik performansi tokom epoha treniranja



Na grafiku su prikazane promjene tačnosti (accuracy) i gubitka (loss) tokom 13 epoha treniranja, nakon čega je EarlyStopping zaustavio proces jer se **val_accuracy** nije poboljšavala tokom 5 uzastopnih epoha, a vraćene su težine iz epohe 8 kao najbolje.

Može se uočiti da je **val_accuracy** tokom cijelog treniranja viša od **train_accuracy**, što ukazuje na odsustvo preobučavanja. Ova pojava je djelimično posljedica primijenjenih tehnika regularizacije — Dropout i BatchNormalization — koje su

aktivne samo tokom treniranja, čineći trening skup "težim" za model. Validaciona kriva osciluje zbog manjeg broja validacionih primjera, ali pokazuje generalni trend rasta.

Na grafiku gubitka obje krive pokazuju opadajući trend, što potvrđuje da model tokom treniranja konstantno napreduje. Finalna **val_accuracy** iznosi 60.97%, a **train_accuracy** 53.55%.

Prikaz rezultata kroz performanse klasifikacije

U tabeli su prikazane vrijednosti metrika klasifikacije na trening i test skupu:


<i>Metrika</i>	<i>Trening skup</i>	<i>Test skup</i>
Tačnost (Accuracy)	57.87%	60.13%
Preciznost(Precision)	63.98%	60.55%
Osjetljivost(Recall)	57.87%	60.13%
F1-skor	59.24%	60.14%

Može se uočiti da su performanse na test skupu nešto više nego na trening skupu, što je neočekivano ali pozitivno — ukazuje na odsustvo preobučavanja. Ova pojava je konzistentna sa grafikom performansi tokom treniranja, gdje je **val_accuracy** bila viša od **train_accuracy**.

Ukupna tačnost od oko 60% je umjerena, što je djelimično očekivano s obzirom na prirodu problema — klasifikacija etničke pripadnosti je vizuelno zahtjevan zadatak jer granice između klasa nisu uvijek jasno definisane. Klase poput *indian* i *other* su posebno teške za razlikovanje zbog preklapanja vizuelnih karakteristika. Dodatno, model je treniran bez GPU podrške što je ograničilo broj epoha i kompleksnost arhitekture.

Preciznost na trening skupu (63.98%) je viša od osjetljivosti (57.87%), što znači da model kada predvidi određenu klasu, češće je u pravu, ali propušta dio tačnih primjera.


Matrice konfuzije



Na matrici konfuzije prikazane su normalizovane vrijednosti predikcija modela na test skupu. Vrijednosti na dijagonali predstavljaju procenat tačno klasifikovanih uzoraka po klasi.

Klasa *white* je najuspješnije klasifikovana sa tačnošću od 76%, što je očekivano s obzirom na njenu dominantnu zastupljenost u datasetu. Klasa *black* postiže tačnost od 63%, dok *asian* dostiže 49%, ali sa značajnim brojem grešaka prema klasi *white* (28%). Klasa *indian* je klasifikovana sa tačnošću od 41% i pokazuje najveće preklapanje sa ostalim klasama — miješana je sa *white* (23%), *black* (15%) i *other* (15%). Najlošije rezultate pokazuje klasa *other* sa svega 22% tačnosti, što je i očekivano jer ova klasa po definiciji obuhvata osobe koje ne pripadaju ni jednoj od ostalih četiri klase, što je čini vizuelno najheterogenijom i najtežom za klasifikaciju. Čak 38% uzoraka klase *other* pogrešno je klasifikovano kao *white*.

Generalno, model pokazuje tendenciju ka predikciji dominantnih klasa (*white* i *black*), što je djelimično ublaženo primijenjenom tehnikom ponderisanja klasa, ali nije u potpunosti eliminirano.




Na matrici konfuzije trening skupa može se uočiti da model postiže najvišu tačnost za klase *asian* (67%), *indian* (64%) i *black* (62%), dok klasa *other* i dalje ostaje najteža sa svega 29% — čak 32% uzoraka klase *other* pogrešno je klasifikovano kao *indian*. Klasa *white* postiže 56% tačnosti na trening skupu.

Poređenje trening i test matrice konfuzije

Upoređivanjem dvije matrice može se uočiti nekoliko zanimljivih obrazaca. Tačnost klase *white* značajno je viša na test skupu (76%) nego na trening skupu (56%), dok je obrnuta situacija kod klase *asian* (67% trening vs 49% test) i *indian* (64% trening vs 41% test). Klasa *black* pokazuje konzistentne rezultate na oba skupa (~62-63%). Klasa *other* ostaje najteža u oba slučaja, što je očekivano zbog njene heterogene prirode.

Odsustvo velikih razlika između trening i test matrice potvrđuje da model nije preobučan, što je konzistentno sa prethodno analiziranim grafikom performansi.

Dobro i loše klasifikovani primerci iz test skupa



Na slici su prikazani primjeri dobro i loše klasifikovanih slika iz test skupa. U gornjem redu nalaze se ispravno klasifikovane slike, dok donji red prikazuje pogrešno klasifikovane primjere. Može se uočiti da model najčešće griješi između klasa koje imaju sličan izgled — npr. *indian* i *black*, ili *black* i *white* u slučajevima lošeg osvjetljenja ili niske rezolucije slike. Ove greške su očekivane s obzirom na to da etnička klasifikacija predstavlja subjektivan i vizuelno zahtjevan zadatak, čak i za ljude.


Projektovanje fuzzy regulatora

Naš objekat (S=5):

$$G(s) = \frac{0.07-0.1s}{(s+0.1)^2} e^{-3s}$$

- Opseg referenci: $r \in [-2, +2]$
- Ograničenje upravljanja: $u \in [-1, +1]$

Analiza objekta



Karakteristike objekta:

- **Red sistema:** 2. red (dva pola u tački $s = -0.1s$)
- **Kašnjenje:** $T_d=3s$ - sistem ne reaguje prvih 3 sekunde nakon promjene upravljačkog signala
- **Statičko pojačanje:** $G(0)=0.07/0.01=7$
- **Neminimalno-fazno ponašanje:** brojnik sadrži nulu u desnoj polu-ravni ($-0.1s + 0.07 = 0 \Rightarrow s = 0.7 > 0$), što uzrokuje kratko odstupanje odziva u pogrešnom smjeru na početku
- **Opseg referenci:** $r \in [-2, +2]$
- **Ograničenje upravljanja:** $u \in [-1, +1]$

Analiza step odziva:

Iz step odziva objekta (bez regulatora) može se uočiti da sistem monotono raste i smiruje se na vrijednost 7 nakon približno 60-70 sekundi. Primjetno je kratko negativno odstupanje na početku odziva (oko $t = 3 - 5s$), što je posljedica neminimalno-faznog ponašanja sistema. Sistem je stabilan ali spor, što nameće potrebu za regulatorom koji će ubrzati odziv i svesti izlaz u željeni opseg.

Projektovanje FIS-a (membership funkcije)

Struktura fuzzy regulatora:

Za upravljanje objektom primijenjen je **intuitivni pristup** projektovanja fuzzy regulatora. Projektovan je **PD fuzzy regulator** (proporcionalno-derivativni) tipa **Mamdani** sa dva ulaza i jednim izlazom:

- **Ulaz 1** — greška $e = r - y$, opseg $[-4, 4]$
- **Ulaz 2** — promena greške de , opseg $[-1, 1]$
- **Izlaz** — upravljački signal u , opseg $[-1, 1]$

Za sve veličine korištene su **trougaone membership funkcije (trimf)** zbog jednostavnosti podešavanja i dobre interpretabilnosti lingvističkih kategorija.

Za grešku e i izlaz u definisano je **5 membership funkcija**, a za de **3 membership funkcije**:



Oznaka	Značenje
NB	Negativno Veliko
NS	Negativno Malo
Z	Nula
PS	Pozitivno Malo
PB	Pozitivno Veliko

Baza pravila sastoji se od **15 pravila** oblika "AKO... I... ONDA...", koja opisuju intuitivno ponašanje regulatora:

e	de	N	Z	P
NB	NB	NB	NB	NS
NS	NB	NB	NS	Z
Z	NS	NS	Z	PS

PS	Z	PS	PB
PB	PS	PB	PB

Logika pravila je sljedeća: što je greška veća, to je upravljački signal agresivniji. Ako greška raste ($de > 0$ za pozitivnu grešku), regulator dodatno pojačava upravljanje, a ako se greška smanjuje, regulator se umiruje.



Upravljačka površina potvrđuje ispravnost definisanih pravila — izlaz regulatora monotonno raste sa povećanjem greške i njene promjene, što je očekivano ponašanje PD regulatora. Površina je antisimetrična u odnosu na ishodište, što garantuje jednako ponašanje za pozitivne i negativne greške.

Simulink model - Sistem 1 (praćenje reference)


Model se sastoji od sljedećih blokova:

- **Step** — generiše referentni signal, step od $r = -2$ na $r = +2$
- **Sum** — računa grešku $e = r - y$
- **Discrete Derivative** — računa promjenu greške de
- **Mux** — spaja e i de u jedan vektor za ulaz u FIS
- **Fuzzy Logic Controller** — prima e i de , primjenjuje fuzzy pravila i daje upravljački signal
- **Gain (pojačanje = 1)** — skaliranje upravljačkog signala
- **Transfer Fcn** — matematički model objekta $G(s)$
- **Scope blokovi** — prikazuju signale u , y , e i de


Rezultati simulacije:

Simulacija je izvršena za vremenski period od 120 sekundi, sa step referansom od $r = -2$ na $r = +2$ u trenutku $t = 0$.


Signal upravljanja u — signal kreće od maksimalne vrijednosti ~ 0.5 , osciluje tokom prolaznog režima i smiruje se na stacionarnu vrijednost ~ 0.2 . Signal ostaje unutar dozvoljenog opsega $[-1, +1]$ tokom cijele simulacije.




Regulisana varijabla y — izlaz sistema prati referencu uz određeno prekoračenje od $\sim 16\%$ (maksimalna vrijednost ~ 1.65). Nakon prolaznog režima sistem se smiruje na vrijednost ~ 1.4 , što ukazuje na prisustvo **statičke greške** od ~ 0.6 .



Greška e — počinje na vrijednosti 2 (jer je $y = 0$ a $r = 2$), smanjuje se tokom regulacije ali se ne svodi na nulu — konačna vrijednost greške iznosi ~ 0.6 , što je posljedica toga što PD regulator **ne eliminiše statičku grešku** (za to bi bio potreban PI ili PID regulator).



Promena greške de — pokazuje veliki impuls na početku simulacije zbog nagle promjene reference, nakon čega se brzo smiruje na nulu.



Projektovani PD fuzzy regulator uspješno prati referentni signal uz prihvatljivo prekoračenje. Međutim, usljed odsustva integralnog djelovanja, sistem pokazuje statičku grešku u stacionarnom stanju. Za eliminaciju statičke greške bilo bi potrebno dodati integralno djelovanje (PID fuzzy regulator) ili povećati pojačanje regulatora.

Simulink model - Sistem 2 (potiskivanje poremećaja)



Projektovan je drugi Simulink model za potiskivanje nenerljivog poremećaja na ulazu objekta upravljanja. Referentna vrijednost je konstantna i iznosi $r=0$, dok se poremećaj d dovodi direktno na ulaz objekta.

Maksimalna amplituda poremećaja jednaka je polovini maksimalne amplitude upravljačkog signala:

$$d_{\max} = u_{\max} / 2 = 1 / 2 = 0.5$$

Vremenski profil poremećaja:

- Od $t = 0$ do $t = 100\text{s}$: $d=0$
- Od $t = 100\text{s}$ do $t = 400\text{s}$: $d = + 0.5$ (pozitivni step)
- Od $t = 400\text{s}$ nadalje: $d = - 0.5$ (negativni step)




Regulisana varijabla y :

Nakon pojave pozitivnog poremećaja u trenutku $t = 100\text{s}$, izlaz sistema se kratkotrajno pomjera do $\sim +2$, ali se zahvaljujući dejstvu fuzzy regulatora brzo vraća na referentnu vrijednost $y = 0$. Slično ponašanje se uočava i nakon negativnog poremećaja u trenutku $t = 400\text{s}$, gdje izlaz pada do ~ -3.5 pa se ponovo vraća na 0. Sistem uspješno potiskuje oba poremećaja bez statičke greške.



Signal upravljanja u :

Kada poremećaj skoči na $+0.5$, regulator odmah reaguje negativnim upravljačkim signalom (~ -0.5) kako bi kompenzovao poremećaj. Nakon smirivanja, signal se stabilizuje na ~ -0.5 . Kada poremećaj skoči na -0.5 , regulator reaguje pozitivnim signalom ($\sim +0.5$) i stabilizuje se na toj vrijednosti. Signal ostaje unutar dozvoljenog opsega $[-1, +1]$.



Ulaz u FIS ($d+u$):

Signal na neposrednom ulazu u fuzzy inference sistem pokazuje impulsne pobude u trenutcima promjene poremećaja, koje se brzo smiruju. Ovo potvrđuje da regulator aktivno reaguje na poremećaje i vraća sistem u ravnotežno stanje.

Sumirane osobine oba sistema

Projektovani PD fuzzy regulator pokazuje zadovoljavajuće performanse u oba scenarija. U sistemu za praćenje reference, regulator uspješno vodi izlaz prema referentnoj vrijednosti uz prihvatljivo prekoračenje, ali uz prisustvo statičke greške usljed odsustva integralnog djelovanja. U sistemu za potiskivanje poremećaja, regulator efikasno neutrališe nemjerljive poremećaje na ulazu objekta i vraća sistem u ravnotežno stanje $y=0$ bez statičke greške, što je očekivano ponašanje za sisteme sa regulacijom poremećaja